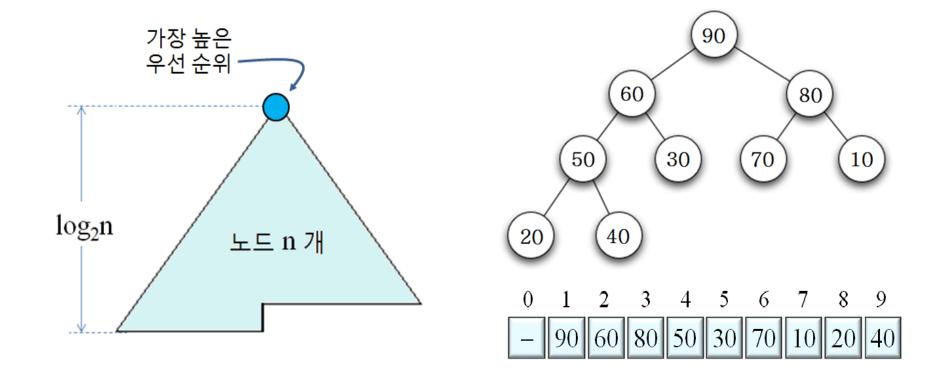
# Chapter 6-2

## Sorting Algorithms

- 이진 힙 (Binary Heap)
  - 힙 조건을 만족하는 완전 이진 트리 (Complete Binary Tree)
  - 힙 조건: 각 노드의 우선 순위 (priority)가 자식 노드의 우선 순위보다 높음
  - 최대 힙 (Maximum Heap): 가장 큰 값이 root에 저장
  - 최소 힙 (Minimum Heap): 가장 작은 값이 root에 저장

- 이진 힙 (Binary Heap)
  - n개의 노드를 가진 힙
    - 완전 이진 트리이므로, 힙의 높이가 log<sub>2</sub>n이며, 노드들을 빈 공간 없이 배열에 저장



- Heap의 노드 관계
  - 힙에서 부모와 자식의 관계
    - A[i]의 부모 = A[i/2]
      - 단, i가 홀수이면 i/2에서 정수 부분만
    - A[i]의 왼쪽 자식 = A[2i]
    - A[i]의 오른쪽 자식 = A[2i+1]

- Heap Sort
  - 정렬할 입력으로 최대 힙 (Max heap)을 만듦
  - 힙 루트에 가장 큰 수가 있으므로, 루트와 힙의 가장 마지막 노드를 교환함
    - 가장 큰 수를 배열의 맨 뒤로 옮긴 것
  - 힙 크기를 1개 줄임
  - 루트에 새로 저장된 숫자로 인해 위배된 힙 조건을 해결하여 힙 조건을 만 족시킴
  - 이 과정을 반복하여 정렬함

• 알고리즘

#### HeapSort

입력: 입력이 A[1]부터 A[n]까지 저장된 배열 A

출력: 정렬된 배열 A

- 1. A의 숫자에 대해서 최대 힙을 구성
- 2. heapSize = n // 힙의 크기를 조절하는 변수
- 3. for i = 1 to n-1
- 4. A[i] ↔ A[heapSize] // 루트와 힙의 마지막 노드 교환
- 5. heapSize = heapSize 1 // 힙의 크기 1 감소
- 6. DownHeap() // 위배된 힙 조건을 만족시킴
- 7. return A

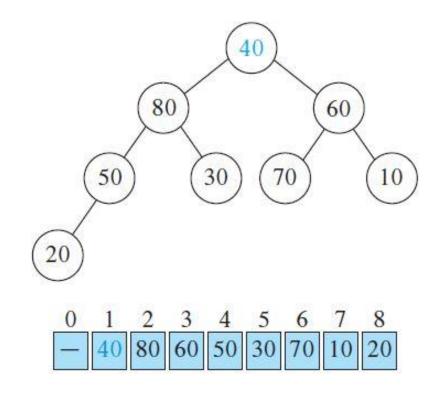
BuildHeap()

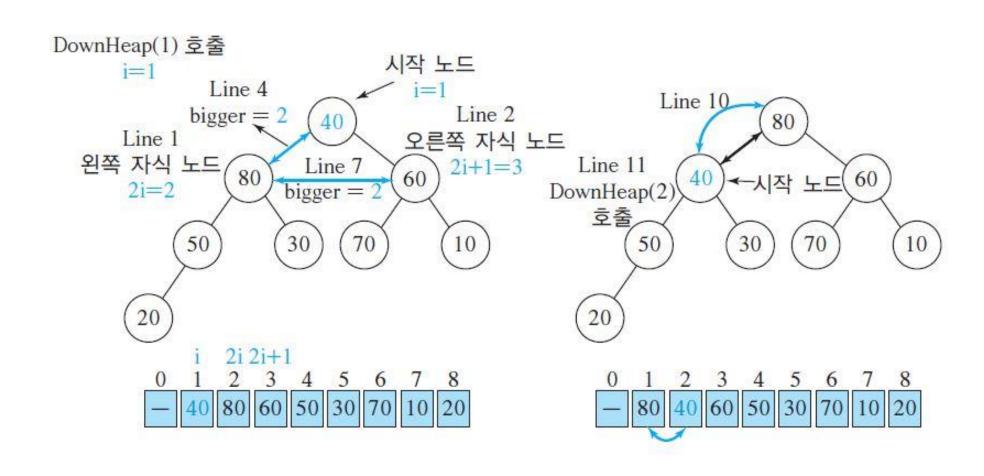
```
BuildHeap (A) {
  for (i= floor[n/2] to 1)
    DownHeap(i)
}
```

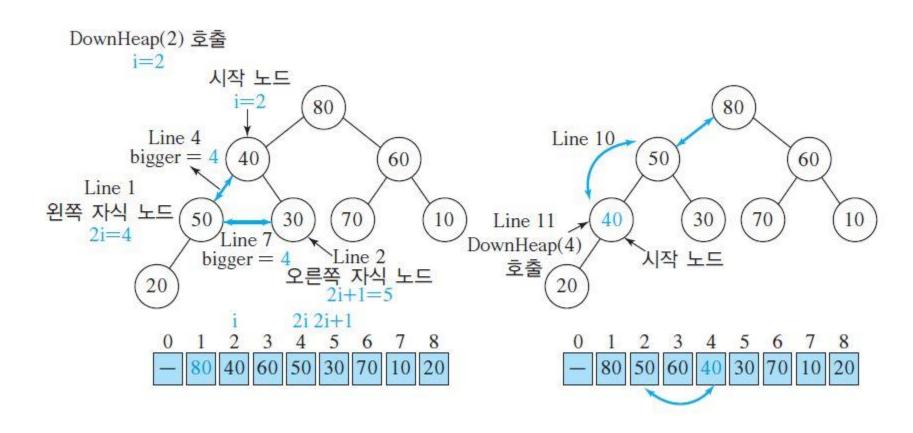
- Downheap()
  - 루트로부터 자식들 중에서 큰 값을 가진 자식과 비교하여 힙 속성이 만족될 때까지 숫자를 교환하며 잎의 방향으로 진행

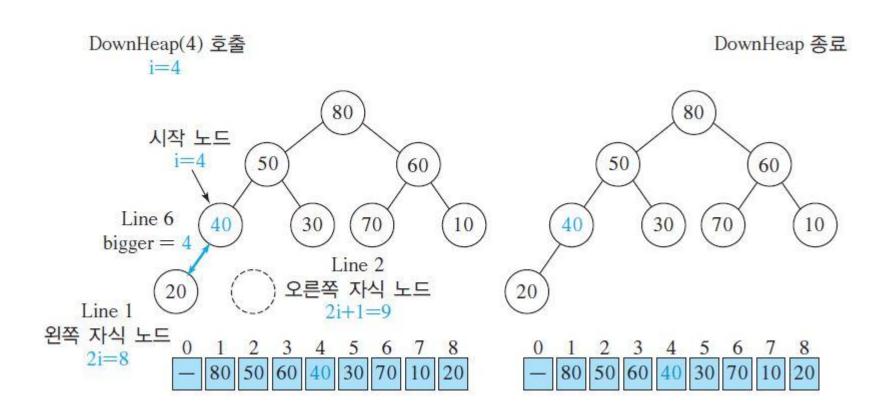
• DownHeap(i)

```
1. leftChild = 2i // i의 왼쪽 자식 노드
2. rightChild = 2i+1 // i의 오른쪽 자식 노드
3. If ((leftChild \leq n) and (A[leftChild] > A[i])
         bigger = leftChild
4.
5. else
6.
         bigger = i
   If ((rightChild <= n) and (A[rightChild] > A[bigger])
         bigger = rightChild
8.
9. If (bigger != i) {
10.
        A[i] \leftrightarrow A[bigger]
11.
         DownHeap(bigger)
12. }
```

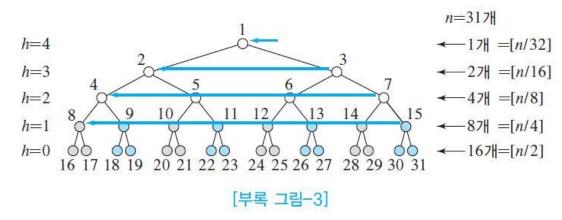




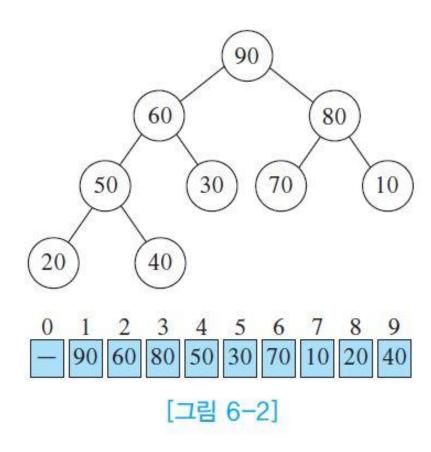




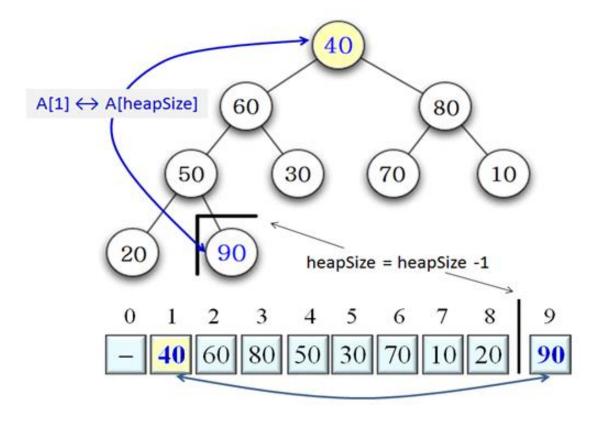
Time Complexity of BuildHeap



• Heap Sort 알고리즘 수행 과정

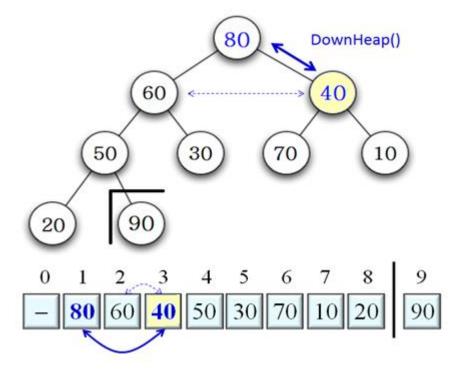


• Heap Sort 알고리즘 수행 과정



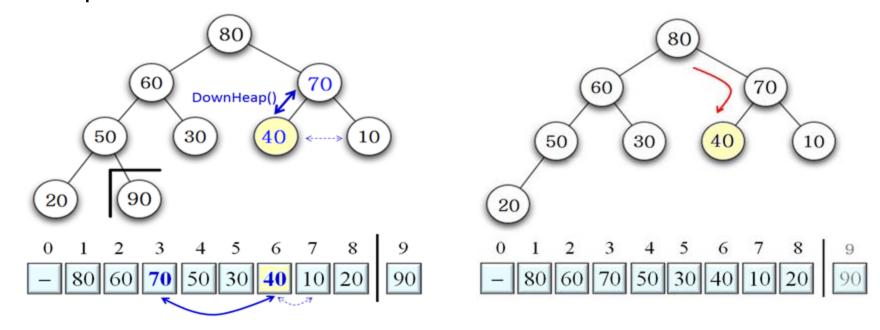
• 힙의 마지막 노드 40과 루트 90을 바꾸고, 힙의 노드수(heapSize) 1 감소

- Heap Sort 알고리즘 수행 과정
  - DownHeap()



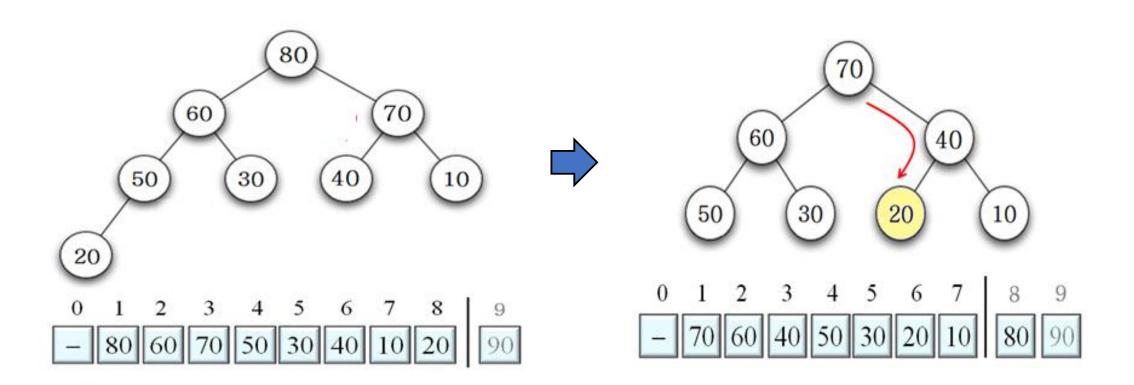
• 새롭게 루트에 저장된 40이 루트의 자식 노드 60과 80보다 작으므로 자식 중에서 큰 자식 80과 루트 40을 교환

- Heap Sort 알고리즘 수행 과정
  - DownHeap()

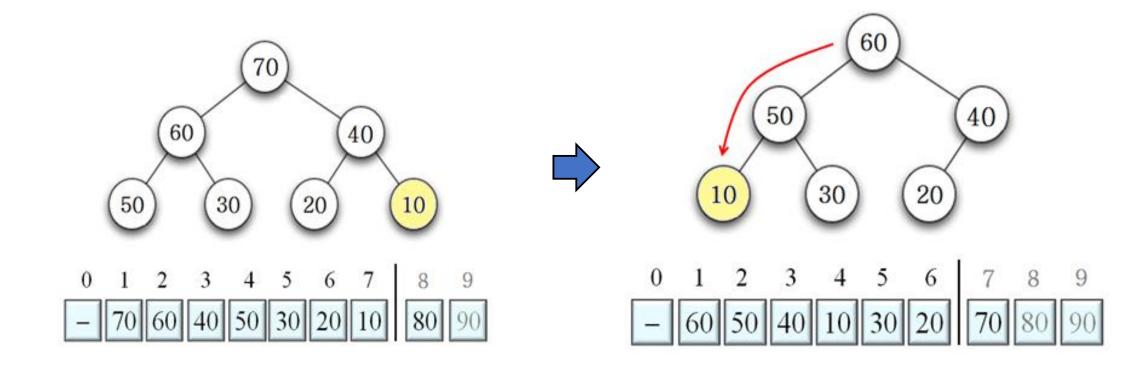


• 40은 다시 자식 노드 70과 10 중에서 큰 자식 70과 비교하여, 70과 40을 교 환

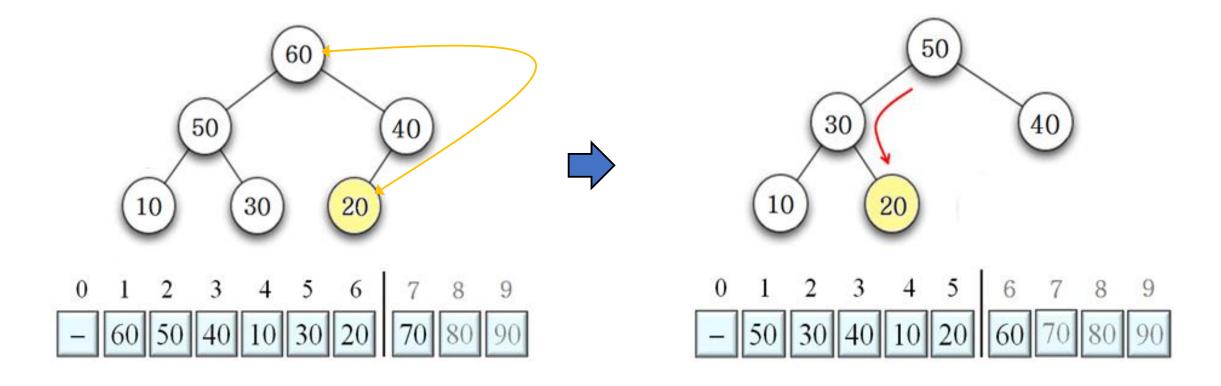
- Heap Sort 알고리즘 수행 과정
  - 80 ↔ 20 교환 후 DownHeap 수행 결과



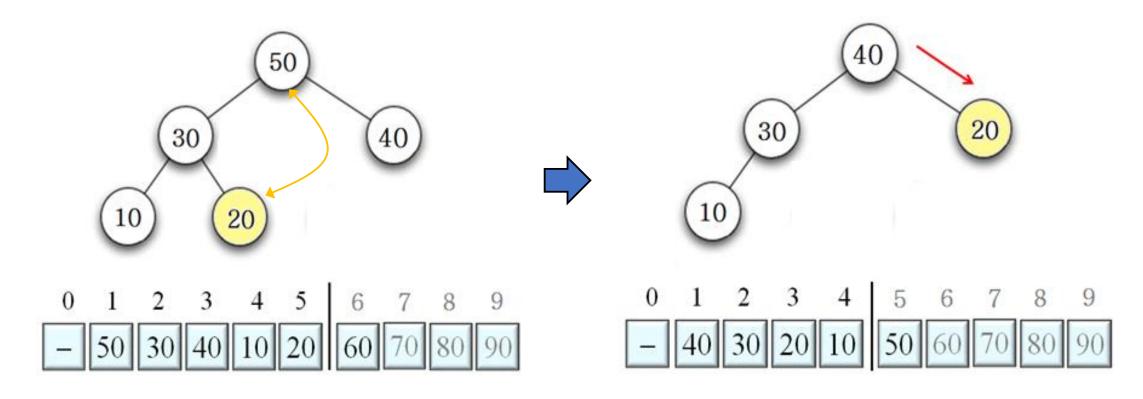
- Heap Sort 알고리즘 수행 과정
  - 70 ↔ 10 교환 후 DownHeap 수행 결과



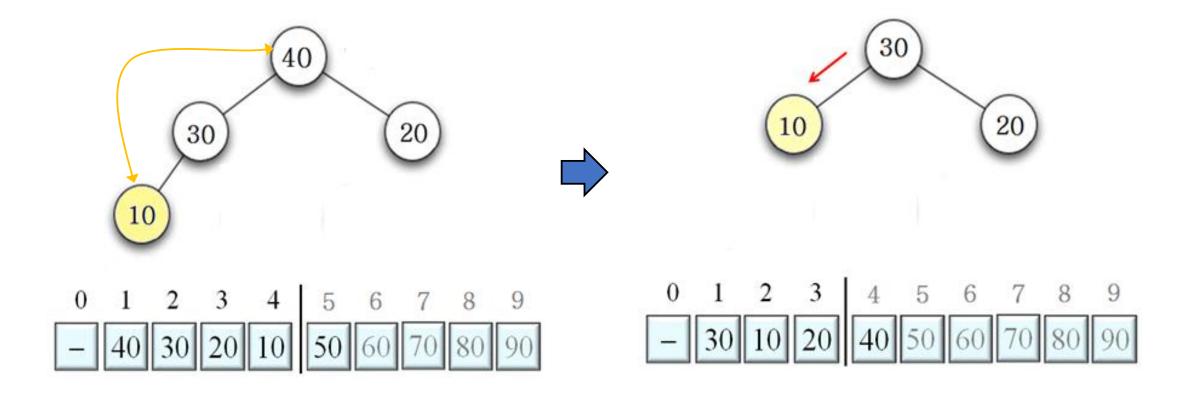
- Heap Sort 알고리즘 수행 과정
  - 60 ↔ 20 교환 후 DownHeap 수행 결과



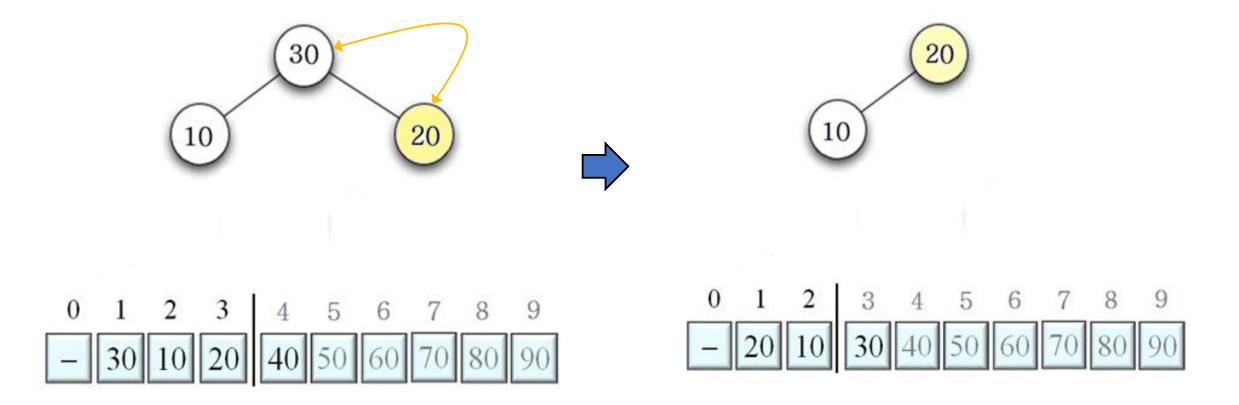
- Heap Sort 알고리즘 수행 과정
  - 50 ↔ 20 교환 후 DownHeap 수행 결과



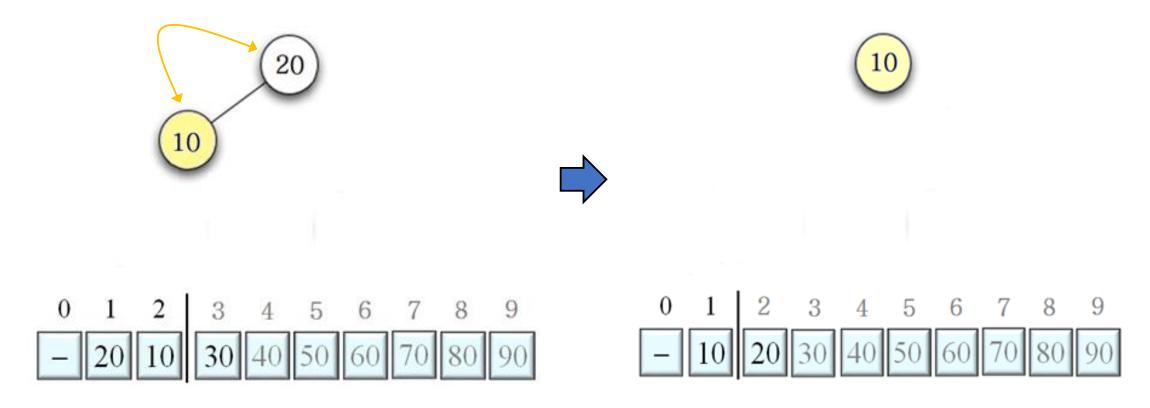
- Heap Sort 알고리즘 수행 과정
  - 40 ↔ 10 교환 후 DownHeap 수행 결과



- Heap Sort 알고리즘 수행 과정
  - 30 ↔ 20 교환 후 DownHeap 수행 결과



- Heap Sort 알고리즘 수행 과정
  - 20 ↔ 10 교환 후 DownHeap 수행 결과



- Time Complexity
  - Heap 만드는 데 O(n) 시간
  - for-loop는 (n-1)번 수행
    - 루프 내부는 O(1) 시간
  - DownHeap은 O(logn) 시간
  - $O(n) + (n-1) \times O(logn) = O(nlogn)$

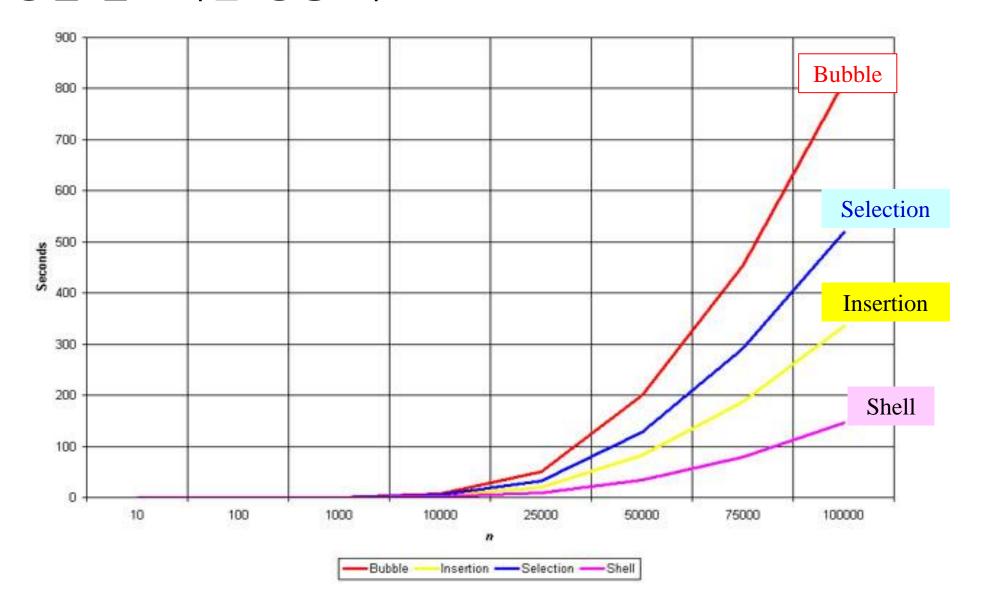
- Heap Sort의 특성
  - 큰 입력에 대해 DownHeap()을 수행할 때 자식을 찾아야 하므로 너무 많은 캐시 미스로 인해 페이지 부재 (page fault)를 야기시킴
  - 최선, 최악, 평균 시간 복잡도가 동일 O(nlogn)

• 내부 정렬 알고리즘 성능 비교

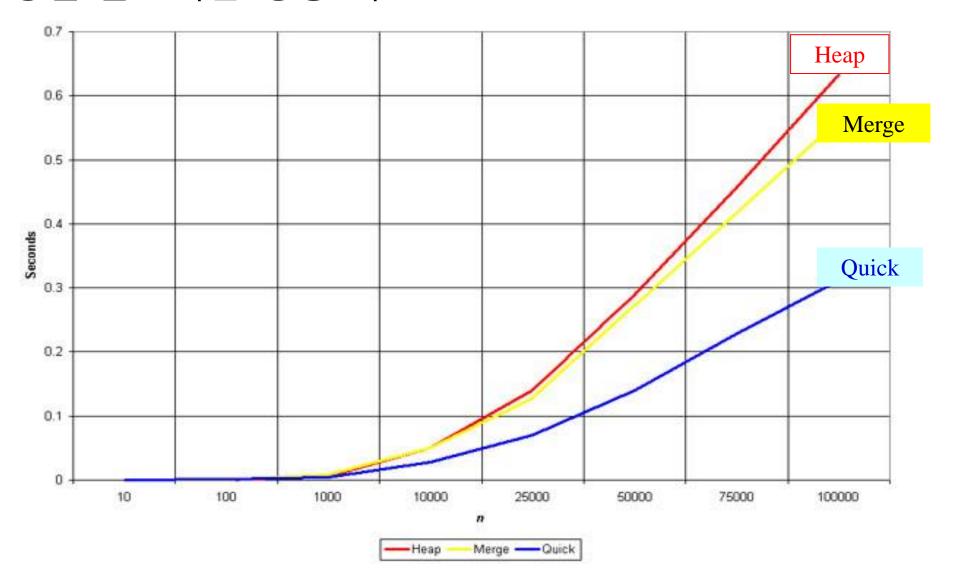
	최선 경우	평균 경우	최악 경우	추가 공간	안정성
선택 정렬	$n^2$	$n^2$	$n^2$	O(1)	X
삽입 정렬	n	$n^2$	$n^{28}$	O(1)	0
쉘 정렬	nlogn	?	$n^{1.5}$	O(1)	X
힙 정렬	nlogn	nlogn	nlogn	O(1)	X
합병 정렬	nlogn	nlogn	nlogn	n	0
퀵 정렬†	nlogn	nlogn	$n^2$	O(1)*	X
Tim Sort	n	nlogn	nlogn	n	0

<sup>\*</sup> 퀵 정렬에서 수행되는 순환 호출까지 고려한 추가 공간은  $O(\log n)$  † 이중 피벗 퀵 정렬의 이론적인 성능은 퀵 정렬과 같다.

• 내부 정렬 알고리즘 성능 비교



• 내부 정렬 알고리즘 성능 비교



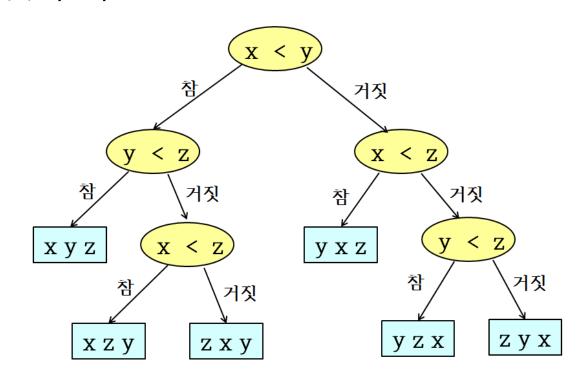
- 비교 정렬 (Comparison Sort)
  - Bubble Sort, Selection Sort, Insertion Sort, Shell Sort, Heap Sort, Merge Sort, Quick Sort의 공통점은 비교가 부분적이 아닌 숫자 대 숫자로 이루어짐

- 기수 정렬 (Radix sort)은 비교 정렬이 아님
  - 숫자들을 한 자리씩 부분적으로 비교

- 어떤 주어진 문제에 대해 Time Complexity의 하한 (lower bound)이라 함은 어떠한 알고리즘도 문제의 하한보다 빠르게 해를 구할 수 없음을 의미
  - 문제의 하한은 어떤 특정 알고리즘에 대한 시간 복잡도의 하한을 뜻하는 것 은 아님
  - 문제가 지닌 고유한 특성 때문에 어떠한 알고리즘일지라도 해를 찾으려면 적어도 하한의 time complexity만큼 시간이 걸린다는 뜻

- 최댓값을 찾는 문제의 하한
  - 최댓값을 찾기 위해 숫자들을 적어도 몇 번 비교해야 하는가?
  - 어떤 방식으로 탐색하든지 적어도 (n-1)번의 비교가 필요
    - 왜냐하면 어떤 방식이라도 각 숫자를 적어도 한 번 비교해야 됨
    - (n-1)보다 작은 비교 횟수가 의미하는 것은 n개의 숫자 중에서 적어도 1개의 숫자는 비교되지 않았다는 것
    - 비교 안 된 숫자가 가장 큰 수일 수도 있기 때문에, (n-1)보다 적은 비교 횟수로는 최댓 값을 항상 찾을 수는 없음

- 정렬 문제의 하한
  - 3개의 서로 다른 숫자 x, y, z에 대해서, 정렬에 필요한 모든 경우의 숫자 대 숫자 비교

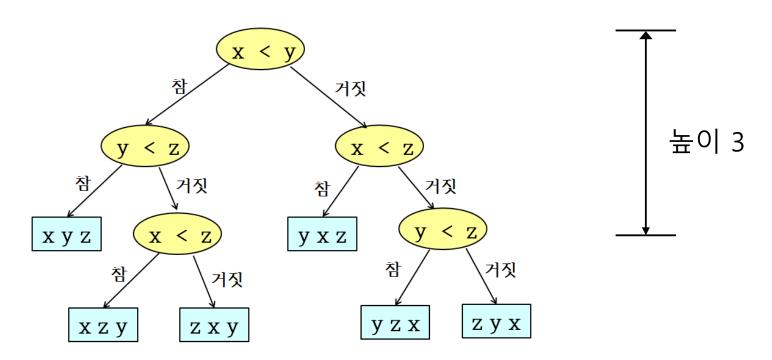


- 각 내부 노드에서는 2개의 숫 자가 비교
- 비교 결과가 참이면 왼쪽으로 거짓이면 오른쪽으로 분기
- 각 잎에서는 정렬된 결과 저장

결정 트리 (Decision Tree)

- 결정 트리의 특징
  - 잎의 수는 3! = 6
  - 결정 트리는 이진 트리 (binary tree)임
  - 결정 트리에는 정렬을 하는데 불필요한 내부 노드가 없음
    - 중복 비교를 하는 노드들이 있으나, 이들은 root로부터 각 잎 노드의 정렬된 결과를 얻기 위해서 반드시 필요한 노드들임

- 정렬 문제의 하한
  - 어느 경우에도 서로 다른 3개의 숫자가 정렬되기 위해서는 적어도 3번의 비교가 필요함
    - 3번의 횟수는 앞의 결정 트리의 높이



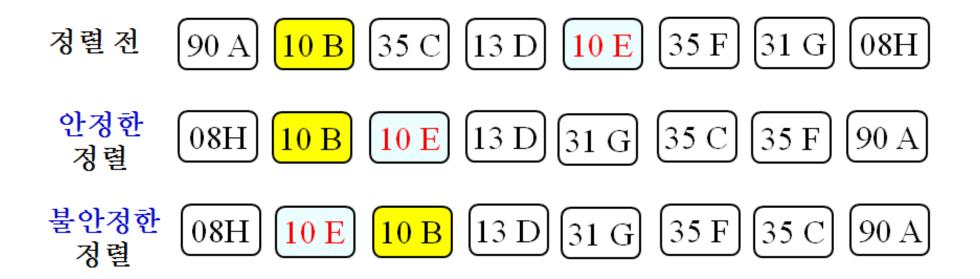
- 정렬 문제의 하한
  - n개의 서로 다른 숫자를 비교 정렬하는 결정 트리의 높이가 비교 정렬의 하 한임
  - k개의 잎이 있는 이진 트리의 높이는 logk보다 큼
  - 따라서 n!개의 잎을 가진 결정 트리의 높이는 log(n!)보다 큼
  - log(n!) = O(nlogn)이므로, 비교 정렬의 하한은 O(nlogn)
    - $n! >= (n/2)^{n/2}$  이므로  $log(n!) >= log(n/2)^{n/2} = (n/2)log(n/2) = O(nlogn)$
  - 즉, O(nlogn)보다 빠른 time complexity를 가진 비교 정렬 알고리즘은 존재 하지 않음
  - 점근적 표기 방식으로 하한을 표기하면 Ω(nlogn)

- 기수 정렬 (Radix Sort)
  - 숫자를 부분적으로 비교하며 정렬
  - 기(radix)는 특정 진수를 나타내는 숫자들
    - 10진수의 기는 0, 1, 2, ..., 9
    - 2진수의 기는 0, 1
  - Radix sort는 제한적인 범위 내에 있는 숫자에 대해서 각 자릿수 별로 정렬하는 알고리즘임

• 기수 정렬 (Radix Sort)

입력	1의 자리	10의 자리	100의 자리
089	070	910	<b>0</b> 35
070	910	131	<b>07</b> 0
035	<u> </u> 131	035	089
[131]	035	070	<b>1</b> 31
910	089	<b>08</b> 9	<b>91</b> 0

- 안정성 (Stability)
  - 입력에 중복된 숫자가 있을 때, 정렬된 후에도 중복된 숫자의 순서가 입력에 서의 순서와 동일하면 정렬 알고리즘이 안정성 (stability)을 가진다고 함



• 알고리즘

#### RadixSort

입력: n개의 r진수의 k자리 숫자

출력: 정렬된 숫자

- 1. for i = 1 to k
- 2. 각 숫자의 i자리 숫자에 대해 안정한 정렬을 수행
- 3. return A

- LSD 기수 정렬
  - RadixSort는 1의 자리부터 k자리로 진행하는 경우, Least Significant Digit(LSD) 기수 정렬 또는 RL (Right-to-Left) 기수 정렬이라고 부름

# • LSD 기수 정렬

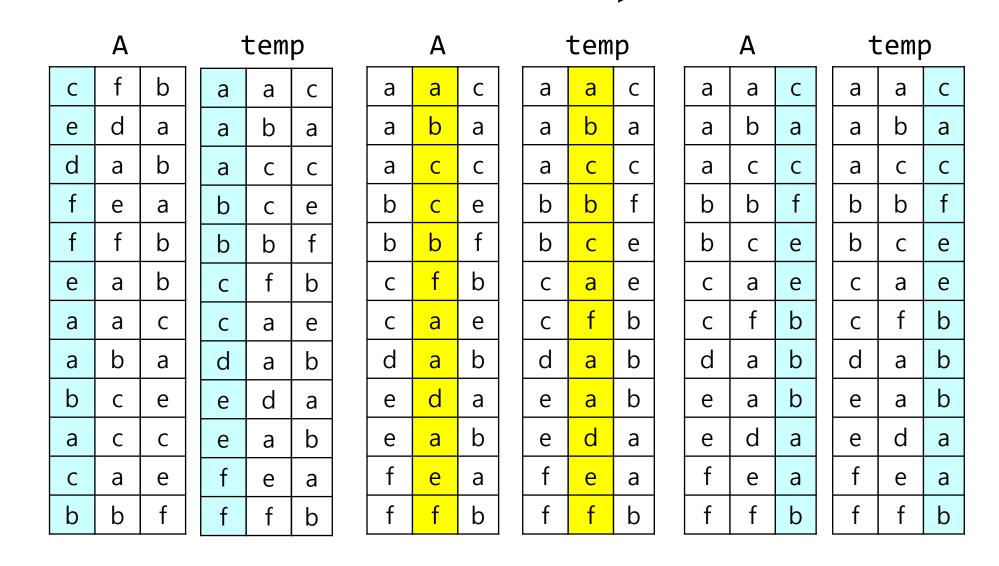
A			temp			
С	f	b		е	d	а
е	d	a		f	е	а
d	a	b		а	Ь	а
f	е	a		С	f	b
f	f	b		d	а	b
е	a	b		f	f	b
а	a	С		е	а	b
а	b	а		а	а	С
b	С	е		а	U	С
а	С	С		b	U	е
С	a	е		C	а	е
b	b	f		b	b	f

Α			temp			
е	d	а		d	а	b
f	е	а		е	а	b
а	b	а		а	а	С
С	f	b		С	а	е
d	а	b		а	b	а
f	f	b		b	b	f
е	а	b		а	С	С
а	a	C		b	С	е
а	С	С		е	d	а
b	С	е		f	е	а
С	а	е		С	f	b
b	b	f		f	f	b

A			temp			
d	а	b		а	а	С
е	а	b		а	b	а
a	а	С		а	С	С
С	а	е		b	C	е
a	b	a		b	b	f
b	b	f		С	а	е
a	С	С		С	f	b
b	C	е		d	а	b
е	d	a		е	а	b
f	e	a		е	d	а
С	f	b		f	е	a
f	f	b		f	f	b

- MSD 기수 정렬
  - k자리로 부터 1의 자리로 진행하는 방식은 Most Significant Digit (MSD) 기수 정렬 또는 LR (Left-to-right) 기수 정렬이라고 부름

#### • MSD 기수 정렬



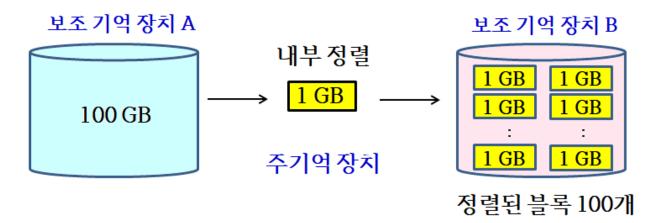
- Time Complexity
  - for-loop가 k번 반복
    - k는 입력의 최대 자릿수
    - Loop가 1회 수행될 때 n개의 숫자의 i자리 수를 읽으며, r개로 분류하여 개수를 세고, 그 결과에 따라 숫자가 이동하므로 O(n+r) 시간 소요

- Time Complexity ○(k(n+r))
  - k나 r이 입력 크기인 n보다 크지 않으면, time complexity는 O(n)

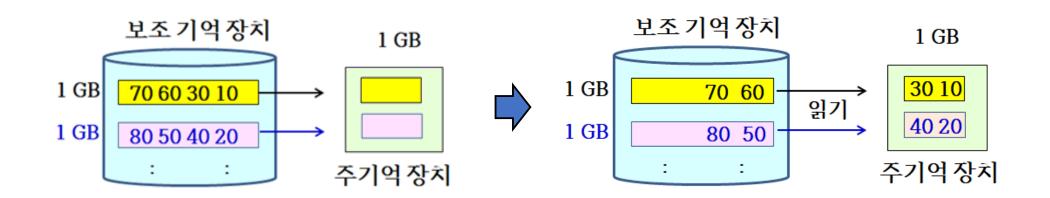
- 내부 정렬 (Internal Sort)
  - 입력이 주기억 장치 (내부 메모리)에 있는 상태에서 정렬이 수행되는 정렬

- 외부 정렬 (External Sort)
  - 입력 크기가 매우 커서 읽고 쓰는 시간이 오래 걸리는 보조 기억 장치에 입력을 저장할 수밖에 없는 상태에서 수행되는 정렬
  - 주기억 장치의 용량이 1GB이고, 입력 크기가 100GB라면, 어떤 내부 정렬 알 고리즘으로도 직접 정렬할 수 없음

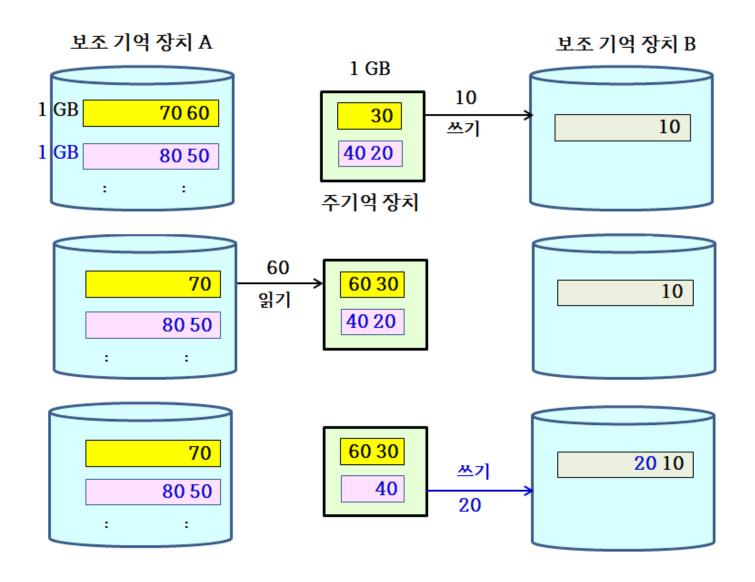
- 주기억 장치에 수용할 만큼 Read/Sort
  - 외부 정렬은 입력은 분할하여 주기억 장치에 수용할 만큼의 데이터에 대해 서만 내부 정렬을 수행하고, 그 결과를 보조 기억 장치에 일단 다시 저장
    - 100GB의 데이터를 1GB 만큼씩 주기억 장치로 읽어 들이고, quick sort와 같은 내부 정렬 알고리즘을 통해 정렬한 후, 다른 보조 기억 장치에 저장
  - 이를 반복하면, 원래의 입력이 100개의 정렬된 블록으로 분할되어 보조 기 억 장치에 저장됨



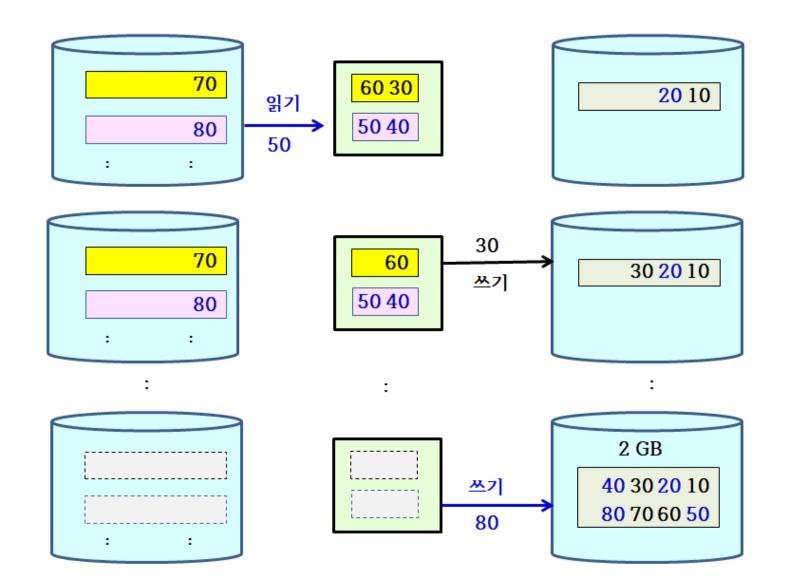
- 정렬된 블록의 합병
  - 정렬된 블록들을 반복적인 합병(merge)을 통해서 하나의 정렬된 거대한 (100GB 크기) 블록으로 만듦
    - 블록들을 부분적으로 주기억 장치에 읽어 들여서, 합병을 수행하여 부분적으로 보조 기억 장치에 쓰는 과정 반복
  - 블록을 부분적으로 읽어 들인 상황



• 1GB 블록 2개가 합병되는 과정



• 1GB 블록 2개가 합병되는 과정



- 1GB 블록 2개가 합병되는 과정
  - 나머지 98개의 블록에 대해서 이와 같이 49회를 반복하면, 2GB 블록이 총 50개 만들어지고
  - 그 다음엔 2GB 블록 2개씩 짝을 지워 합병하는 과정을 총 25회 수행하면, 4GB 블록 25개가 만들어짐
  - 이러한 방식으로 계속 합병을 진행하면, 블록 크기가 2배로 커지고 블록의 수는 1/2로 줄어들게 되어 결국에는 100GB 블록 1개만 남음

- 1GB 블록 2개가 합병되는 과정
  - 외부 정렬 알고리즘은 보조 기억 장치에서의 읽고 쓰기를 최소화하는 것이 매우 중요
    - 왜냐하면 보조 기억 장치의 접근 시간이 주기억 장치의 접근 시간보다 매우 오래 걸리 기 때문
  - ExternalSort()
    - M : 주기억 장치의 용량
    - 외부 정렬 알고리즘은 입력이 저장된 보조 기억 장치 외에 별도의 보조 기억 장치 사용
    - 알고리즘에서 보조 기억 장치는 'HDD'임

알고리즘 ExternalSort

입력: 입력 데이터에 저장된 입력 HDD

출력: 정렬된 데이터가 저장된 출력 HDD

- 1. 입력 HDD에 저장된 입력을 M만큼씩 주기억 장치에 읽어 들인 후 내부 정렬 알고리즘으로 정렬하여 별도의 HDD에 저장함. 다음 단계에서 별도의 HDD는 입력 HDD로 사용되고, 입력 HDD는 출력 HDD로 사용
- 2. while 입력 HDD에 저장된 블록 수 > 1
- 3. 입력 HDD에 저장된 블록을 2개씩 선택하여, 각각의 블록으로부터 데이터를 부분적으로 주기억 장치에 읽어 들여서 합병을 수행함. 이때 합병된 결과는 출력 HDD에 저장함. 단, 입 력 HDD에 저장된 블록 수가 홀수일 때에는 마지막 블록은 그대로 출력 HDD에 저장
- 4. 입력과 출력 HDD의 역할을 바꾼다
- 5. return 출력 HDD

- External Sort의 수행 과정
  - 128GB 입력과 1GB의 주기억 장치에 대한 ExternalSort의 수행 과정
    - 1GB의 정렬된 블록 128개를 별도의 HDD에 저장
    - 2GB의 정렬된 블록 64개가 출력 HDD에 만들어짐
    - 4GB의 정렬된 블록 32개가 출력 HDD에 만들어짐
    - 8GB의 정렬된 블록 16개가 출력 HDD에 만들어짐

•

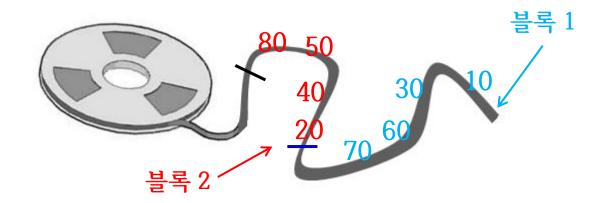
- 64GB의 정렬된 블록 2개가 출력 HDD에 만들어짐
- 128GB의 정렬된 블록 1개가 출력 HDD에 만들어짐
- 출력 HDD를 return

- Time Complexity
  - 외부 정렬은 전체 데이터를 몇 번 처리(읽고 쓰기)하는가를 가지고 시간 복 잡도를 측정
  - 패스(pass): 전체 데이터를 1회 처리하는 것
  - External Sort 알고리즘에서는 line 3에서 전체 데이터를 입력 HDD에서 읽고 합병하여 출력 HDD에 저장함
    - 즉, 1 패스가 수행됨
  - while-loop가 수행된 횟수가 알고리즘의 time complexity

- Time Complexity
  - 입력 크기가 N이고, 메모리 크기가 M이라고 하면, line 3이 수행될 때마다 블록 크기가 2M, 4M, ..., 2<sup>k</sup>M으로 (2배) 증가
  - 마지막에 만들어진 1개의 블록 크기가  $2^kM$ 이면 이 블록은 입력 전체가 합병된 결과를 가지므로,  $2^kM = N$ 
    - k는 while-loop가 수행된 횟수
    - $2^k = N/M$
    - $k = log_2(N/M)$
  - Time complexity: O(log(N/M))

- 2-way 합병
  - ExternalSort 알고리즘에서는 하나의 보조 기억 장치에서 2개의 블록을 동시에 주기억 장치로 읽어 들일 수 있다는 가정
  - 2개의 블록이 각각 다른 보조 기억 장치에서 읽어 들여야 하는 경우도 있음
  - 테이프 드라이브 저장 장치는 블록을 순차적으로만 읽고 쓰는 장치이므로, 2개의 블록을 동시에 주기억 장치로 읽어 들일 수 없음

- 2-way 합병
  - 블록 1이 [10 30 60 70], 블록 2가 [20 40 50 80], 이 두 블록을 합병하려면 블록 1의 10을 읽고, 블록 2의 20을 읽어서 비교해야 함



• 테이프를 한쪽 방향으로만 테이프가 감기므로, 합병하려면 블록 2의 20을 읽은 후 다시 되감아 블록 1의 두 번째 숫자인 30을 읽을 수 없음

- 테이프 드라이브에서 ExternalSort 알고리즘
  - ExternalSort 알고리즘의 line 3에서 2개의 블록을 읽어 들여 합병하면서 만들어지는 블록들을 2개의 저장 장치에 번갈아 저장

• 2-way 합병 수행 과정



• 2-way 합병 수행 과정

```
TD 0
TD 1
                                                              pass 1
        블록 1 + 블록 2
                       블록5+블록6
TD2
                       블록7+블록8
        블록 3+블록 4
TD3
TD 0
       블록 1 + 블록 2 + 블록 3 + 블록 4
                                                                pass 2
TD 1
       <u>블록 5 + 블록 6 + 블록 7 + 블록 8</u>
TD 2
TD 3
TD 0
TD 1
                                                                pass 3
TD 2
      블록 1 + 블록 2 + 블록 3 + 블록 4 + 블록 5 + 블록 6 + 블록 7 + 블록 8
```